SPILLERVERDI-ESTIMATOR

Simon Hollekve, 30. okt. 2026

1: BESKRIV PROBLEMET

OMFANG / *SCOPE*

Målet med prosjektet er en modell som anslår markedsverdien til en fotballspiller ut fra sesongstatistikk og profilinformasjon, og et verktøy som peker ut spillere som virker billige sammenlignet med prestasjonene. Den ferdige modellen bommer typisk med 42 % på spillere den ikke har sett, mot 70 % for en enkel oppslagstabell.

Hvem produktet er for. Målgruppen er speidere og klubber med lite budsjett.

Hvordan løsningen brukes.

Verktøyet brukes til to ting:

1. Et raskt førsteanslag på hva en spiller med gitte nøkkeltall (alder, liga, posisjon, kontrakt, spilletid, mål og assist) er verdt.
2. En sammenligning mellom Transfermarkt-verdien og modellens anslag for ekte spillere, slik at speideren får en kortliste over kandidater som er verdt å se nærmere på.

Hvordan problemet løses i dag. Markedsverdier settes i dag i stor grad manuelt. Transfermarkt baserer verdiene på vurderinger fra eksperter og brukere, og speidere vurderer spillere ved å se kamper og video.

Hvorfor maskinlæring passer. Verdien avhenger av mange faktorer samtidig, og de virker sammen. En ung spiller i en topp-liga med lang kontrakt og Champions League-minutter er verdt langt mer enn summen av hver faktor for seg. Slike samspill er vanskelige å fange med faste regler, men en trebasert modell lærer dem fra data. I tillegg kan modellen vurdere tusenvis av spillere på sekunder, noe ingen speider kan.

Pipeline og komponenter. Systemet består av fire deler:

1. Rådata fra Kaggle (Transfermarkt-tabellene players, appearances og competitions).
2. Databehandling i notebooks: kobling, filtrering, rensing og feature engineering.
3. Modelltrening og lagring av modellen med joblib.
4. En Streamlit-app som laster modellen og en liten spillertabell.

Business objective. Gevinsten for en klubb er å kjøpe spillere under markedsverdi, eller å unngå å betale for mye. Én vellykket signering av en undervurdert spiller kan være verdt flere millioner euro i senere videresalg. Lønnsomheten kan måles som forskjellen mellom kjøpspris og senere markedsverdi for spillere funnet med verktøyet, sammenlignet med spillere funnet på vanlig måte.

Ressurser. Prosjektet krever lite. Treningen tar sekunder på en vanlig bærbar PC, dataene er gratis tilgjengelige, og appen kjører gratis på Streamlit Community Cloud. Personellbehovet er en liten gruppe studenter. I praksis trengs også en speider som kan vurdere kandidatene modellen foreslår.

Metrikker

Vi bruker to maskinlæringsmetrikker, beregnet i euro etter at prediksjonene er transformert tilbake fra log-skala:

- **Median relativ feil**, Den svarer på hvor mange prosent modellen typisk bommer for en vanlig spiller. Medianen brukes fordi noen få ekstreme bom ellers ville dominert. Dette er hovedmetrikken, fordi en speider tenker i relative størrelser: å bomme med 1 million er mye for en spiller verdt 500 000 €, men lite for en verdt 50 millioner.
- **MAE (gjennomsnittlig absolutt feil) i euro.** Den domineres av de dyreste spillerne, og viser hvor store pengebeløp feilene utgjør.

Som software-metrikk er responstid relevant: et anslag i appen skal komme på under ett sekund, slik at verktøyet kan brukes interaktivt.

Minimum for suksess. Modellen må slå baselinen tydelig, med minst 20 prosentpoeng lavere median relativ feil. Med 42 % mot 70 % er kravet oppfylt. For forretningsmålet er et rimelig minimum at speidere vurderer en betydelig andel av kandidatene på kortlisten, for eksempel minst halvparten, som verdt å følge opp. Dette har vi ikke kunnet måle i prosjektet, men det er det første som bør testes med ekte brukere.

2: DATA

Datagrunnlaget er 5 391 spillere fra sesongen 2025/26, bygget fra et offentlig Transfermarkt-datasett på Kaggle (David Cariboo. Football Data from Transfermarkt. https://www.kaggle.com/datasets/davidcariboo/player-scores?resource=download.)

Datakilde og mengde. Jeg bruker tre tabeller fra datasettet:

Tabell	Rader	Innhold
players	50 149	Én rad per spiller: fødselsdato, posisjon, fot, høyde, kontrakt, klubb, liga og markedsverdi
appearances	1 894 350	Én rad per spiller per kamp: dato, turnering, minutter, mål, assist og kort
competitions	65	Turneringer med id og navn, brukt til å finne at Champions League har id CL

Dataene er strukturerte tabelldata. Kampdataene går fra juli 2012 til 28. juni 2026, så hele sesongen 2025/26 er med.

Labels. Målvariabelen er market_value_in_eur, Transfermarkts markedsverdi. Dette er et regresjonsproblem, og labelene følger med datasettet. Verdiene er vurderinger gjort av eksperter og brukere på Transfermarkt, ikke faktiske overgangssummer. De er heller ikke helt konsistente: de er avrundet (500 000, 1,5 mill. osv.), de oppdateres med ulike mellomrom, og for spillere som har forsvunnet fra datasettet er verdien utdatert. Det siste håndterer jeg ved bare å ta med spillere med last_season = 2025, altså de som er aktive i sesongen 2025/26.

Kobling av tabellene. Koblingen skjer i fire steg:

1. appearances filtreres til kamper mellom 1. juli 2025 og 30. juni 2026.
2. Kampene summeres per spiller med groupby: antall kamper, minutter, mål, assist og gule kort. Minutter i Champions League (competition_id = "CL") summeres i en egen kolonne. Spillere uten CL-kamper får 0.
3. Summene kobles med spillerprofilen i players via player_id (inner join).
4. Alder og år igjen av kontrakten regnes ut fra en felles referansedato, 30. juni 2026.

Filtre. Av 9 051 spillere som spilte i sesongen, står 5 391 igjen etter to filtre:

- **Minst 450 minutter**, altså fem hele kamper. Med mindre spilletid blir statistikken for tilfeldig: en innbytter med ett mål på 20 minutter ville fått 4,5 mål per 90 minutter.
- **Markedsverdi over 0.** Spillere uten verdi har ingen label og kan ikke brukes i trening.

Hvorfor highest_market_value_in_eur er utelatt. Kolonnen er spillerens høyeste markedsverdi gjennom karrieren. Den er satt av de samme ekspertene som målvariabelen, og for mange aktive spillere er den lik dagens verdi. Å ta den med ville gitt modellen fasiten som input. Feilen ville sett mye lavere ut, men modellen ville bare

gjentatt markedets vurdering, og den ville vært ubrukelig til å finne undervurderte spillere.

Rensing. Etter filtreringen manglet noen verdier:

Kolonne	Mangler	Håndtering
contract_years_left	551	Median, pluss en egen kolonne contract_missing (0/1)
international_caps / international_goals	853	Fylt med 0, under antakelsen at spilleren ikke har landskamper
foot	46	Egen kategori "unknown"
height_in_cm	39	Median

Indikatorkolonnen for manglende kontrakt lar modellen lære om det å mangle kontraktsdato i seg selv sier noe, for eksempel at spilleren er på lån. Ligaer med færre enn 50 spillere er slått sammen til kategorien "annet", fordi modellen ikke kan lære noe pålitelig fra få eksempler.

Feature engineering og representasjon. Modellen bruker 18 features:

- **Numeriske (14):** alder, høyde, år igjen av kontrakten, contract_missing, kamper, minutter, mål, assist, gule kort, mål per 90, assist per 90, CL-minutter, landskamper og landskampmål.
- **Kategoriske (4):** posisjon, underposisjon, foretrukket fot og liga.

Mål og assist per 90 minutter gjør spillere med ulik spilletid sammenlignbare. De numeriske kolonnene skaleres med StandardScaler, og de kategoriske gjøres om til 0/1-kolonner med OneHotEncoder. Begge deler skjer i en scikit-learn Pipeline, slik at skaleringen bare lærer fra treningsdataene.

Skjev målvariabel. Markedsverdien er sterkt høyreskjev: de fleste spillere er verdt under 3 millioner euro, mens noen få er verdt over 100. Skjevheten er 11,75. Etter transformasjonen log1p (log(1 + x)) er den 0,70, nesten symmetrisk. Derfor trenes alle modellene på log1p(verdi). Det får modellen til å optimalisere relative feil i stedet for absolutte, som passer med hovedmetrikken.

Personvern og etikk. Dataene gjelder ekte personer og inneholder personopplysninger som navn, fødselsdato og statsborgerskap. Opplysningene er offentlig tilgjengelige på Transfermarkt, og vi bruker ingen sensitive opplysninger. Navn brukes bare til å

identifisere spillere i appen, ikke som feature, og statsborgerskap er ikke med i modellen.

Hvor mye data som trengs. 5 391 spillere er nok til å slå baselinen tydelig. Mer data ville likevel hjulpet, spesielt for ligaene som er slått sammen til "annet" og for de yngste spillerne, der feilen er størst. Den enkleste utvidelsen er å bruke flere sesonger.

3: MODELLERING

HistGradientBoosting var best, med 42,2 % median relativ feil på testsettet mot 70,0 % for baselinen.

Oppsett. Dataene ble delt i trening (70 %, 3 773 spillere), validering (15 %, 809) og test (15 %, 809) med random_state=42. Valideringssettet ble brukt til å sammenligne modeller. Testsettet ble brukt bare én gang, på den valgte modellen, slik at testresultatet er et ærlig mål på ytelsen.

Baseline. Som baseline uten maskinlæring brukte jeg median markedsverdi per kombinasjon av liga og posisjon, regnet ut på treningsdataene. Dette tilsvarer en oppslagstabell en speider kunne brukt. Finnes ikke kombinasjonen, brukes medianen for ligaen, og deretter for alle spillere. Tabellen viser et tydelig ligahierarki: en angriper i Premier League har median 28 mill. €, mot 7–9 mill. i Italia, Tyskland og Frankrike og 0,5–2,5 mill. i de fleste mindre ligaene. Keepere er billigst i nesten alle ligaer.

Modeller. Alle modellene ligger i samme Pipeline med skalering og one-hot-koding, og trenes på log1p(verdi) via TransformedTargetRegressor, som gjør prediksjonene om tilbake til euro. Vi prøvde tre modeller:

- **Ridge:** lineær regresjon med regularisering, som en enkel referanse.
- **Random Forest:** 300 beslutningstrær trent på tilfeldige utvalg og gjennomsnittet av dem.
- **HistGradientBoosting:** trær som bygges etter hverandre, der hvert tre retter feilene til de forrige.

Resultater på valideringssettet:

Modell	Median relativ feil	MAE (mill. €)
HistGradientBoosting	41,8 %	3,35
Random Forest	47,6 %	3,82
Ridge	48,1 %	5,53

Baseline (liga × posisjon)	70,0 %	5,79

På testsettet fikk HistGradientBoosting 42,2 % median relativ feil og MAE på 3,45 mill. €, mot 70,0 % og 5,96 mill. € for baselinen. Begge metrikkene er omtrent 40 % lavere enn baselinen. Validering og test gir nesten samme tall, så modellen er ikke tilpasset valideringssettet.

Ridge og Random Forest har nesten lik median feil, men Ridge har mye høyere MAE. Den lineære modellen bommer altså stort på de dyreste spillerne. Den fanger ikke samspill som at ung alder, topp-liga og Champions League sammen gir ekstra høy verdi, noe trebaserte modeller gjør.

Feature importance. Jeg målte permutation importance på 1 618 spillere fra validerings- og testsettet: hver feature stokkes tilfeldig, og økningen i feil (målt på log-skala) viser hvor viktig den er. Liga (0,39) og alder (0,28) er klart viktigst, og betyr mer enn alle andre features til sammen. Deretter følger spilletid (kamper 0,11, minutter 0,07), år igjen av kontrakten (0,09), CL-minutter (0,08) og landskamper (0,06). Mål og assist betyr lite (0,01–0,02), og posisjon nesten ingenting.

Markedsverdien bestemmes altså mer av kontekst enn av prestasjonstall. Et forbehold er at features som henger tett sammen, som kamper og minutter, eller mål og mål per 90, deler på viktigheten. Prestasjon samlet er derfor litt viktigere enn hvert enkelt tall antyder.

Feilanalyse. Feilen synker med alderen, fra 50 % for spillere på 21 år eller yngre til 36 % for 31–33-åringer. Verdien til unge spillere bygger på potensial, som modellen ikke ser. Modellen treffer best i Spania og England (32–33 %) og dårligst i "annet" (55 %) og i Portugal, Danmark, Belgia og Nederland (45–49 %). "Annet" blander mange ligaer med ulikt prisnivå, og de fire andre er typiske salgsligaer der unge spillere prises etter hva større klubber kan betale senere.

Undervurderte spillere. Vi rangerte spillerne etter forholdet mellom predikert og faktisk verdi. Uten filter havner nesten bare spillere verdt under 150 000 € øverst, fordi forholdstallet eksploderer når faktisk verdi er lav. Vi krevde derfor minst 0,5 mill. € i verdi og 900 minutter spilletid, som ga 1 122 kandidater. Topp 15 faller i tre grupper:

1. **Produktive spillere med lav prislapp:** Raúl García (ES1, 14 mål, priset til 3 mill. mot predikert 17,1 mill.), Mathis Suray (NL1, 15 mål), Júnior Brumado (DK1, 16 mål) og Omri Gandelman (IT1, 9 mål fra midtbanen).
2. **Unge, faste spillere i mellomstore ligaer:** blant andre Valdemar Byskov (21 år, DK1) og Yaroslav Shevchenko (19 år, UKR1). Her er usikkerheten størst.

3. **Blindsoner i modellen:** Martin Dúbravka (37 år, keeper i GB1) får høy prediksjon av liga og spilletid, mens markedet priser inn at karrieren snart er over. Dailon Livramento (IT1, 0 mål) løftes trolig av liga alene.

4: DEPLOYMENT

Modellen kjører i en Streamlit-app på Streamlit Community Cloud: https://spillerverdi-estimator.streamlit.app/. Koden ligger i et offentlig GitHub-repo: https://github.com/798663/spillerverdi-estimator.

Endelig modell. HistGradientBoosting ble trent på nytt på alle 5 391 spillere og lagret med joblib. Testresultatet på 42 % er fortsatt vårt anslag på ytelsen, siden modellen trent på alle data ikke kan evalueres på nytt. Appen leser bare modellfilen og en liten spillertabell. Rådataene ligger ikke i repoet, men README-en forklarer hvordan de lastes ned. Versjonene av scikit-learn og de andre pakkene er låst i requirements.txt, slik at miljøet i skyen er likt det modellen ble trent i.

Hvordan prediksjonene brukes. Appen har to faner:

1. **Estimer verdi:** brukeren oppgir alder, posisjon, liga, år igjen av kontrakten, minutter, mål og assist, og får et estimat på sekundet. De andre featurene settes til medianen for spillere i samme posisjon.
2. **Sjekk en ekte spiller:** brukeren velger en spiller og ser Transfermarkt-verdien, modellens anslag og forholdet mellom dem. Anslagene er laget med 5-fold kryssvalidering, så hver spiller er predikert av en modell som ikke har sett ham. Ellers ville modellen ha "husket" verdien, og sammenligningen ville vært misvisende.

Appen kaller en spiller undervurdert først når modellens anslag er over 1,5 ganger Transfermarkt-verdien, og overvurdert under 0,67 ganger. Siden modellen typisk bommer med 42 %, ville mindre forskjeller bare vært vanlig modellfeil presentert som funn.

Monitorering og vedlikehold. Markedsverdier endrer seg hver sesong, og prisnivået stiger over tid. Modellen må derfor trenes på nytt minst én gang per sesong, helst etter hvert overgangsvindu. Det bør overvåkes:

- **Data drift:** nye ligaer, endrede ligakoder eller kolonnenavn i datasettet, og endringer i fordelingen av markedsverdier.
- **Ytelse:** median relativ feil på nye verdier fra Transfermarkt, sammenlignet med 42 %.
- **Bruk:** hvor mange kandidater fra kortlisten speidere faktisk følger opp.

Begrensninger.

- Transfermarkt-verdier er eksperters vurderinger, ikke faktiske overgangssummer. Modellen lærer å gjenskape vurderingene, ikke hva klubber betaler.
- Datasettet dekker ikke alle ligaer, og små ligaer er slått sammen til "annet".
- Dataene stopper i juni 2026 og gjelder bare én sesong.
- Modellen ser ikke skader, potensial, form eller kontraktsforhandlinger.
- Liga er ligaen til spillerens nåværende klubb. Ved lån eller overgang midt i sesongen kan statistikken komme fra en annen liga.
- Medianene brukt i rensingen ble regnet på hele datasettet før oppdelingen, noe som gir en liten risiko for leakage.

Videre forbedringer. Den viktigste forbedringen er å bruke flere sesonger, både for mer data og for features som viser utvikling over tid. Andre forbedringer er avanserte statistikker som forventede mål (xG), prediksjonsintervaller i stedet for ett tall, og en tydeligere effekt av kort kontrakt, som modellen i dag undervurderer.

5: REFERANSER

1. David Cariboo. Football Data from Transfermarkt. Kaggle. https://www.kaggle.com/datasets/davidcariboo/player-scores?resource=download. Lastet ned 25.10.2026.

2. Pedregosa, F. mfl. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

3. The pandas development team. pandas. https://pandas.pydata.org

4. Harris, C. R. mfl. (2020). Array programming with NumPy. *Nature*, 585, 357–362.

5. Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95.

6. Streamlit. https://streamlit.io

7. joblib. https://joblib.readthedocs.io